

Optimización Basada en Biogeografía (BBO)

Trabajo Final – Metaheurísticas

Leandro Jorge Fernández Vega

Universidad de Granada
Doble Grado en Ingeniería Informática y Matemáticas

Curso 2025–2026



Contenido

- 1 Introducción
- 2 Fundamentos Teóricos de BBO
- 3 Algoritmo BBO Base
- 4 Mejoras: BBOImproved
- 5 Variantes Meméticas
- 6 Problema del Portfolio
- 7 Benchmark CEC2017
- 8 Resultados: Portfolio
- 9 Resultados: CEC2017
- 10 Conclusiones

Metaheurísticas

Estrategias de optimización de propósito general para problemas donde los métodos exactos resultan inviables.

Algoritmo estudiado: *Biogeography-Based Optimization* (BBO)

- Propuesto por **Dan Simon** (2008)
- Metaheurística **poblacional** inspirada en la biogeografía
- Basada en los modelos de migración de especies de **MacArthur y Wilson**

Variantes implementadas:

- 1 BBO base
- 2 BBOImproved – Elitismo + Migración combinada + Mutación gaussiana
- 3 BBOLocalSearch – Hibridación con BL del Portfolio
- 4 BBOSolisWets – Hibridación con Solis-Wets

Problema del Portfolio

- Asignación óptima de capital entre N activos
- Maximizar retorno, minimizar riesgo
- Restricciones de suma y rango
- 3 datasets: IBEX35, S&P100, S&P500

Benchmark CEC2017

- 30 funciones de optimización continua
- Dominio $[-100, 100]^D$
- Funciones seleccionadas: F_4, F_5, F_{21}
- Dimensiones: $D \in \{10, 30, 50\}$

- **Hábitat (isla):** Área geográficamente aislada que alberga especies
- **HSI** (*Habitat Suitability Index*): calidad del hábitat $\equiv$ *fitness*
- **SIVs** (*Suitability Index Variables*): variables que determinan la habitabilidad $\equiv$ variables de decisión

Analogía con la Optimización

Biogeografía	Optimización
Hábitat	Solución candidata
HSI	Fitness
SIV	Variable de decisión
Migración	Compartir información

Modelo de Equilibrio de MacArthur-Wilson

Modelo continuo

El número de especies S evoluciona según:

$$\frac{dS}{dt} = \lambda(S) - \mu(S)$$

$$\lambda(S) = I \left(1 - \frac{S}{S_{max}} \right) \quad \mu(S) = E \cdot \frac{S}{S_{max}}$$

Punto de equilibrio:

$$S^* = \frac{I \cdot S_{max}}{I + E}$$

Discretización para BBO

Cada hábitat tiene un rango $i \in \{0, \dots, N-1\}$ por fitness. Tasas lineales:

$$\lambda_i = 1 - \frac{i}{N} \quad (\text{inmigración})$$

$$\mu_i = \frac{i}{N} \quad (\text{emigración})$$

- **Peor** ($i = 0$): $\lambda_0 = 1$, $\mu_0 = 0 \rightarrow$ recibe todo
- **Mejor** ($i = N-1$): $\lambda \approx 0$, $\mu \approx 1 \rightarrow$ aporta todo

Derivación

La dinámica se modela como un proceso de nacimiento-muerte. Balance detallado:

$$\lambda_s \cdot P_s = \mu_{s+1} \cdot P_{s+1}$$

Resolviendo recursivamente y normalizando:

$$P_s = \frac{\binom{N-1}{s}}{2^{N-1}}$$

Interpretación

Distribución binomial simétrica (campana centrada en $(N-1)/2$):

- **Rangos intermedios:** más probables (equilibrio estable)
- **Rangos extremos:** improbables (estados transitorios)

⇒ Fundamenta el operador de **mutación**: los hábitats en rangos improbables reciben mayor perturbación.

Migración

Para cada hábitat i y SIV j :

- 1 Con probabilidad λ_i , seleccionar fuente k por **ruleta** sobre μ
- 2 Copiar: $pop[i][j] \leftarrow pop_copia[k][j]$
- 3 Reparar y reevaluar si hubo cambios

Prob. de seleccionar fuente k :

$$\Pr(\text{fuente} = k) = \frac{2k}{N(N-1)}$$

Mutación

Tasa inversamente proporcional a P_s :

$$m_i = m_{max} \cdot \left(1 - \frac{P_i}{P_{max}}\right)$$

- **Rangos intermedios:** $m_i \approx 0$ (ya mejoran por migración)
- **Rangos extremos:** $m_i \approx m_{max}$ (necesitan perturbación)

SIV mutado $\leftarrow$ valor uniforme en todo el dominio

Bucle Principal del BBO

Pseudocódigo del BBO Base

```
1: Generar población de  $N$  hábitats aleatorios; evaluar fitness
2: Ordenar población (ascendente: mejor al final)
3: Pre-computar:  $P \leftarrow$  probabilidades de especies,  $\lambda, \mu \leftarrow$  tasas de migración
4: while evaluaciones  $<$  max_evals do
5:    $pop\_copia \leftarrow pop$  ▷ Snapshot previo a la migración
6:   MIGRAR( $pop, pop\_copia, \lambda, \mu$ )
7:   MUTAR( $pop, P, P_{max}$ )
8:   Ordenar población por fitness
9:   DESPUÉSDEGENERACIÓN() ▷ Hook para variantes
10: end while
11: return mejor hábitat
```

- Las tasas λ, μ y probabilidades P son **fijas** (población de tamaño constante)
- Las soluciones **no mueren**: sobreviven y se adaptan (a diferencia de los Algoritmos Genéticos)

BBOImproved: Tres Modificaciones Clave

1. Elitismo

Los E mejores hábitats quedan **excluidos** de migración y mutación.

Memoria persistente de las mejores soluciones descubiertas.

$$N_{proc} = N - E$$

2. Migración combinada

Combinación convexa en lugar de copia directa:

$$x_i^{(j)} \leftarrow \alpha \cdot x_{src}^{(j)} + (1-\alpha) \cdot x_i^{(j)}$$

$$\alpha \sim U(0, 1)$$

Preserva información parcial de ambos hábitats.

3. Mutación gaussiana

Perturbación local en lugar de reemplazo global:

$$x_i^{(j)} += \mathcal{N}(0, \sigma^2)$$

$$\sigma = \sigma_g \cdot (b - a)$$

Desplazamiento $\sim 8\%$ del rango vs. $\sim 33\%$ uniforme.

Migración combinada vs. directa

Directa (BBO base): $x' = y \rightarrow$ destruye información del receptor

Combinada (BBOImproved):

$$\mathbb{E}[x'] = \frac{x + y}{2}$$

$$\text{Var}(x') = \frac{(y - x)^2}{12}$$

El valor resultante se distribuye uniformemente en $[\text{mín}(x, y), \text{máx}(x, y)]$: genera valores **nuevos** que no existían en la población.

Mutación gaussiana vs. uniforme

Uniforme: $\mathbb{E}[|x' - x|] \approx 0,33 \cdot (b - a)$
 $\Rightarrow$ Exploración **global** (saltos grandes)

Gaussiana: $\mathbb{E}[|\varepsilon|] \approx 0,08 \cdot (b - a)$
 $\Rightarrow$ Explotación **local** (refinamiento progresivo)

Solo el 4,6 % de perturbaciones exceden $2\sigma \rightarrow$ concentra la búsqueda en el vecindario local.

Variantes Meméticas de BBO

Combinan la exploración global del BBO con explotación local mediante el hook `DESPUÉSDEGENERACIÓN`.

BBOLocalSearch (Portfolio)

- Cada G_{LS} generaciones, aplica **Búsqueda Local** (Primero el Mejor) al mejor hábitat
- Movimiento: transferencia de capital entre activos ($ratio = 40\%$)
- Específica del Portfolio
- Reemplazo lamarckiano

BBOSolisWets (General)

- Cada G_{SW} generaciones, aplica **Solis-Wets** al mejor hábitat
- Perturbaciones aleatorias con **memoria de dirección**
- Tamaño de paso **adaptativo**: $\times 2$ tras 5 éxitos, $/2$ tras 3 fallos
- Aplicable a cualquier problema continuo

Formulación del Problema Portfolio

Representación

Vector de pesos $w \in \mathbb{R}^N$:

- $\sum_{i=1}^N w_i = 1$ (presupuesto total)
- $w_i \in [lo, hi] \cup \{0\}$ (rango de inversión)

Datasets

Dataset	N	Días	$[lo, hi]$
IBEX35	30	2813	$[0,005, 0,08]$
S&P100	97	2765	$[0,005, 0,05]$
S&P500	457	2765	$[0,005, 0,02]$

Función Objetivo

$$fitness(w) = B(w) - \lambda \cdot R(w)$$

$$B(w) = \sum_i w_i \sum_t \log(1 + \mu_{ti})$$

$$R(w) = \sqrt{w^T \Sigma w}$$

$\lambda = 500$ (aversión al riesgo)

Operador de Reparación

- 1 Normalizar: $w_i \leftarrow w_i / \sum w$
- 2 Forzar límites: $w_i < lo \Rightarrow 0$
- 3 Asegurar mínimo de activos
- 4 Redistribución iterativa hasta $\sum w_i = 1$

Características

- 30 funciones en $[-100, 100]^D$
- 4 categorías: unimodales, multimodales, híbridas, composición
- Óptimo global: $f(x^*) = k \times 100$
- Fitness: $-f_{CEC}(x)$ (negación para maximizar)

Operadores simplificados

- **Reparación:** clamping a $[-B, B]$
- **Generación:** $x_i \sim U(-B, B)$ i.i.d.
- Sin restricciones de suma ni correlaciones

Funciones seleccionadas

- F_4 **Rastrigin rotada:** multimodal con óptimos equidistantes $\rightarrow$ evalúa **exploración**
- F_5 **Scaffer's F6 rotada:** no separable, acopla pares de variables $\rightarrow$ evalúa **explotación con dependencias**
- F_{21} **Composición 1:** combina Rosenbrock, Elipsoidal y Rastrigin $\rightarrow$ evalúa **adaptabilidad**

Algoritmos de referencia

jSO, ELSHADE_SPACMA, EBOwithCMAR
(Top 3 de la competición CEC2017)


Parámetros comunes

- **50 ejecuciones** independientes (semillas 42–91)
- $max_evals = 10\,000$
- 18 algoritmos comparados en 4 familias
- BBO: $N = 100$, $m_{max} = 0,1$, $E = 2$
- $\sigma_g = 0,1$, BL cada 5 gen., 200 evals/invocación

Familias de algoritmos


- **Baselines:** RandomSearch, Greedy, LocalSearch
- **Algoritmos Genéticos:** AGG, AGE, AM (6 variantes)
- **Trayectorias:** ES, BMB, ILS_BL, ILS_ES
- **BBO:** BBO, BBOImproved, BBOLocalSearch, BBOSolisWets

Resultados IBEX 35




Distribución en **Train**

- BBO base: rendimiento moderado, dispersión amplia
- BBOImproved mejora al base pero queda por debajo de GA/AM e ILS
- En baja dimensionalidad, las trayectorias superan a todas las variantes de BBO




Distribución en **Test**

Resultados S&P 100




Distribución en **Train**



Distribución en **Test**


- BBOImproved reduce la brecha con los AM (media dimensionalidad)
- Las variantes meméticas (BBOLocalSearch, BBOSolisWets) no mejoran al BBO base
- AM_Best y AGG_BLX se mantienen como los mejores algoritmos

Resultados S&P 500



Distribución en **Train**

- **BBOImproved supera a todas las técnicas de trayectorias** en alta dimensionalidad
- Mejora del $\sim 19\%$ respecto al BBO base
- Los AM mantienen ventaja clara, pero la brecha se reduce



Distribución en **Test**

BBO base vs. BBOImproved

- Mejora **consistente** en los 3 datasets
- Ventaja **creciente con la dimensionalidad**
- Migración combinada: genera valores intermedios preservando información
- Mutación gaussiana: refinamiento local
- Menor dispersión entre ejecuciones

Variantes meméticas: sin mejora

- $\text{BBOLocalSearch} \approx \text{BBOSolisWets} \approx \text{BBO base}$
- **Causa:** la BL consume evaluaciones sin aportar mejoras suficientes
- Presupuesto insuficiente para generar avances significativos
- Mejor invertir **todas** las evaluaciones en operadores poblacionales mejorados

Limitación principal del BBO

La migración **componente a componente** fragmenta las correlaciones entre pesos de activos. Los GA combinan soluciones completas (cruce $\text{BLX-}\alpha$), preservando mejor estas correlaciones.


Parámetros específicos

- Población: $N = 50$
- Mutación: $m_{max} = 0,01$
- Presupuesto: $10\,000 \times D$ evaluaciones
- 10 ejecuciones por (función, dimensión)
- Elitismo: $E = 2$, $\sigma_g = 0,1$
- Dominio: $[-100, 100]^D$


Error medio final: $f(x) - f(x^*)$. Mejor resultado en **negrita**.

Función	D	EBOwithCMAR	ELSHADE	SPACMA	BBOImproved	jSO
F_4 (Rastrigin)	10	0.00e+00		0.00e+00	6.33e+00	0.00e+00
F_4 (Rastrigin)	30	5.65e+01		0.00e+00	1.00e+02	5.87e+01
F_4 (Rastrigin)	50	4.29e+01		5.68e-01	1.29e+02	5.62e+01
F_5 (Scaffer's F6)	10	0.00e+00		1.35e+00	1.63e+01	1.76e+00
F_5 (Scaffer's F6)	30	2.78e+00		3.69e+00	1.06e+02	8.56e+00
F_5 (Scaffer's F6)	50	7.58e+00		6.22e+00	2.10e+02	1.64e+01
F_{21} (Composición)	10	1.14e+02		1.54e+02	2.15e+02	1.32e+02
F_{21} (Composición)	30	1.99e+02		2.09e+02	3.08e+02	2.09e+02
F_{21} (Composición)	50	2.11e+02		2.15e+02	4.30e+02	2.19e+02


Convergencia: F_4 (Rastrigin)



$D = 10$




$D = 30$




$D = 50$

- Exponencial número de óptimos locales equidistantes
- La migración reduce diversidad $\rightarrow$ convergencia prematura hacia la cuenca del mejor óptimo local
- BBO se estanca tras una fracción reducida del presupuesto; los algoritmos de referencia continúan reduciendo el error


Convergencia: F_5 (Scaffer's F_6)



$D = 10$




$D = 30$




$D = 50$

- Función **no separable**: acopla pares de variables
- La migración componente a componente modifica una variable sin ajustar su pareja → ineficaz
- DE opera con **vectores diferencia completos**, preservando dependencias entre variables


Convergencia: F_{21} (Composición)



$D = 10$



$D = 30$



$D = 50$

- Paisaje **heterogéneo**: distintas regiones gobernadas por funciones base diferentes
- La transferencia componente a componente destruye las correlaciones que cada subfunción requiere
- Los algoritmos de referencia (DE, CMA-ES) se adaptan a la geometría local del paisaje

Sobre las variantes de BBO

- **BBOImproved** es la mejor variante: mejora consistente y creciente con la dimensionalidad
- Las variantes meméticas **no aportan mejora**: la BL consume evaluaciones sin compensar el coste
- Bajo presupuesto limitado, es preferible invertir en **operadores poblacionales mejorados**

Portfolio

- BBOImproved **supera a las trayectorias** en alta dimensionalidad (S&P500)
- Los AM mantienen ventaja por su cruce de soluciones **completas**
- Todos los poblacionales generalizan bien en Test (retornos positivos)

CEC2017

- BBOImproved **no alcanza el estado del arte** (jSO, ELSHADE, EBOwithCMAR)
- Debilidad fundamental: migración **componente a componente** no captura correlaciones
- El rendimiento relativo se **degrada con la dimensionalidad**

Líneas de Trabajo Futuro

- **Migración por bloques de variables** para preservar correlaciones inter-dimensionales
- **Adaptación dinámica** de σ_g y tasas de migración durante la ejecución
- Explorar **presupuestos mayores** para las variantes meméticas

Gracias por su Atención

¿Preguntas?

