

- 1) Imaginemos que, en el contexto de SIFT, partimos de una imagen que tiene un $\sigma_{ini}=0.3$, y queremos llevar esta imagen a $\sigma_{fin}=1.0$. ¿Con qué sigma (σ_{incr}) tenemos que suavizar la imagen inicial para obtener una imagen con el sigma deseado?

a) $\sigma_{incr} \approx 0.95$

$$\sigma_{incr}^2 = \sigma_{fin}^2 - \sigma_{ini}^2 \Rightarrow \sigma_{incr} = \sqrt{1^2 - 0.3^2} \approx 0.95$$

b) $\sigma_{incr} \approx 1.04$

c) $\sigma_{incr} \approx 0.91$

d) $\sigma_{incr} \approx 1.09$

- 2) ¿Cuál de las siguientes afirmaciones relativas a SIFT y Harris es correcta?

a) Harris usa segundas derivadas en la second moment matrix (SMM) para detectar esquinas, mientras que SIFT usa diferencia de Gaussianas (DoG) para detectar regiones. *↑ son primeras derivadas*

b) SIFT emplea una aproximación multiescala en un espacio de escalas Gaussiano, y propone un descriptor basado en gradientes invariante a cambios de perspectiva. *No de perspectiva, sino rotación.*

c) Harris asocia esquinas con regiones en donde los gradientes tanto en X como en Y son muy elevados.

d) Todas las anteriores son erróneas.

- 3) Tenemos una imagen tricanal (RGB), y queremos escalarla al intervalo [0, 1] conservando los colores, es decir, conservando la relación entre los valores de cada canal (rojo, verde, azul). ¿Cómo deberíamos operar?

a) Deberíamos escalar de modo independiente cada canal, restando la media (de cada canal) y dividiendo por la desviación típica (de cada canal).

b) Deberíamos escalar de modo independiente cada canal, restando el mínimo (de cada canal) y dividiendo por la diferencia entre el máximo y el mínimo (de cada canal).

c) Deberíamos escalar los 3 canales conjuntamente, restando el mínimo y dividiendo por la diferencia entre el máximo y el mínimo, considerando que el máximo es 255 y el mínimo 0.

d) Deberíamos pasar la imagen a escala de grises, escalarla allí, y luego volver a RGB.

- 4) ¿Cuál de las siguientes afirmaciones sobre el dominio de Fourier es correcta?

a) Convolución en el dominio del espacio es equivalente a multiplicación en el dominio de la frecuencia.

b) Asumiendo que una imagen de Fourier muestra solamente la magnitud de las frecuencias implicadas, entre -k y k, las frecuencias más bajas se representan en torno al centro de la imagen.

c) La transformada de Fourier de una Gaussiana es otra Gaussiana con una anchura inversamente proporcional al sigma empleado en el dominio del espacio (es decir, a mayor sigma tendremos un mayor ancho en el dominio del espacio, y la Gaussiana en el dominio de la frecuencia será más estrecha).

d) Todas las anteriores son correctas.

- 5) El rango de una matriz es el número máximo de filas (o columnas) que son linealmente independientes. ¿Cuál es el rango que debe tener un kernel 3x3 para ser directamente separable en dos kernels 1D?
- 0
 - ☒ 1
 - 2
 - 3
- 6) ¿Cuál de las siguientes afirmaciones sobre homografías es correcta?
- Una homografía es una matriz 3x3 con 9 grados de libertad. *True 8*
 - ☒ Una homografía es una matriz cuyo determinante es distinto de cero.
 - Una homografía preserva el paralelismo y las proporciones de la imagen original.
 - Todas las anteriores son erróneas.
- 7) ¿Cuál de las siguientes afirmaciones es correcta?
- Reducir el batch size está asociado con entrenamientos más rápidos. *Al contrario*
 - Los mínimos de la función de pérdida encontrados con grandes batch sizes tienden a ubicarse en flat minima, favoreciendo una mejor capacidad de generalización. *Batch sizes grandes no generalizan bien.*
 - ☒ Reducir el learning rate está asociado con una mayor tendencia al sobreajuste, e incrementarlo (dentro de unos límites) con una mayor velocidad de convergencia.
 - Todas las anteriores son correctas.
- 8) ¿Cuál de las afirmaciones siguientes sobre procesamiento de imagen es cierta?
- Las derivadas en X detectan bordes horizontales, y las derivadas en Y detectan bordes verticales.
 - La magnitud del gradiente puede tener valores negativos, dado que el gradiente puede hacer referencia a pendientes positivas o negativas.
 - El gradiente en una imagen es mayor en las regiones planas que en las zonas con bordes.
 - ☒ Ninguna de las anteriores es correcta.
- 9) Imaginemos que disponemos de un volumen de entrada de tamaño 14x14x64. Si ahora realizamos la convolución con 128 filtros 7x7, con padding=2 y stride=3. ¿Cuáles serán las dimensiones del volumen de salida?
- $$N_{out} = \left\lfloor \frac{N - F + 2P}{S} + 1 \right\rfloor = \left\lfloor \frac{14 - 7 + 2 \cdot 2}{3} + 1 \right\rfloor = 4$$
- $$X_{out} \in \mathbb{R}^{4 \times 4 \times 128}$$
- 5x5x128
 - 4x4x64
 - ☒ 4x4x128
 - 5x5x64

10) Si partimos de una imagen de entrada de 224×224 , ¿cuántas capas convolucionales 3×3 (stride 1) debemos encadenar para que el campo receptivo ocupe, al menos, toda la imagen?



a) 1

b) 56

☒ c) 112

d) Ninguna de las anteriores.

11) ¿Cuál de las siguientes afirmaciones sobre dropout tiene más sentido en relación a las siguientes gráficas de entrenamiento?



☒ a) La gráfica de la izquierda posiblemente emplea dropout y la de la derecha no. *sacrifica rendimiento para generalizar mejor.*

b) La gráfica de la izquierda posiblemente no emplea dropout y la de la derecha sí.

c) Seguramente ambas empleen dropout dado que, en ambos casos, las curvas de entrenamiento oscilan mucho.

d) Ninguna de las dos emplea dropout porque, si se emplea dropout, no se puede alcanzar un rendimiento tan bueno en tan pocas iteraciones.

- 12) ¿Cuántos pesos (es decir, parámetros entrenables/aprendibles), incluyendo bias, tiene la siguiente red neuronal? Nota: el propio alumnado debe calcular el valor indicado en primera FC layer (indicado con interrogantes: "???"), que se corresponde con el flattening del volumen de activaciones precedente.

	Layer Type	Kernel Size (for conv layers)	Input Output dimension	Input Output channels (for conv layers)	
1	Conv	3x3	32x32 32x32	3 64	$(3^2 \cdot 3 + 1)64 = 1792$
	ReLU	-	32x32 32x32	-	
2	BN	-	32x32 32x32	-	$2 \cdot 64 = 128$
3	Conv	3x3	32x32 32x32	64 64	$(3^2 \cdot 64 + 1)64 = 36928$
	ReLU	-	32x32 32x32	-	
4	BN	-	32x32 32x32	-	$2 \cdot 64 = 128$
	MaxPooling	2x2	32x32 16x16	-	
5	Conv	3x3	16x16 16x16	64 64	$(3^2 \cdot 64 + 1)64 = 36928$
	ReLU	-	16x16 16x16	-	
6	BN	-	16x16 16x16	-	$2 \cdot 64 = 128$
7	Conv	3x3	16x16 16x16	64 64	$(3^2 \cdot 64 + 1)64 = 36928$
	ReLU	-	16x16 16x16	-	
8	BN	-	16x16 16x16	-	$2 \cdot 64 = 128$
	MaxPooling	2x2	16x16 8x8	-	
9	FC	-	X ??? 128	-	$(4096 + 1)128 = 524416$
10	BN	-	128 128	-	$2 \cdot 128 = 256$
	Dropout	-	128 128	-	
	ReLU	-	128 128	-	
11	FC	-	128 25	-	$(128 + 1)25 = 3225$
					640985

a) 640985

b) 648921

c) 640576

d) Ninguno de los anteriores.

Dimensión de salida de la capa anterior
 $x = 8 \cdot 8 \cdot 64 = 4096$
 ↓
 n° canales

N° parámetros
 Conv layer: $(F^2 + 1)k$
 BN layer: $2c$
 FC layer: $(i+1)out$

- 13) ¿Cuáles de las siguientes afirmaciones relativas a la operación de convolución son correctas?


a) La convolución es equivariante con la traslación.

b) La convolución no es equivariante con el escalado.

c) La convolución no es equivariante con la rotación.

d) Todas las anteriores son correctas.

14) La siguiente figura representa el perfil de un kernel 1D. ¿Qué tipo de filtro representa?



- a) Un kernel de suavizado Gaussiano. *→ No está normalizado. Solo el centro ya suma 1.*
 b) Un kernel de primeras derivadas. *→ No suma 0.*
 c) Un kernel de segundas derivadas.
 d) Ninguno de los anteriores.

15) Teniendo en cuenta que la expresión de la Laplaciana de la Gaussiana (LoG) (sin normalizar) es

$$\nabla^2 g = \frac{\partial^2 g}{\partial x^2} + \frac{\partial^2 g}{\partial y^2} = \frac{1}{\pi \sigma^4} \left(1 - \frac{x^2 + y^2}{2\sigma^2} \right) e^{-\frac{x^2 + y^2}{2\sigma^2}}$$


y que la ecuación de un círculo centrado en el origen (0,0) es $x^2 + y^2 = r^2$, ¿a qué escala (σ) la Laplaciana alcanza máxima respuesta para un círculo binario de radio r ?

- a) $\sigma = r/\sqrt{2}$ *$\nabla^2 g = 0 \Rightarrow 1 - \frac{r^2}{2\sigma^2} = 0 \Rightarrow \sigma = \sqrt{\frac{r^2}{2}} = r/\sqrt{2}$*
 b) $\sigma = r \cdot \sqrt{2}$
 c) $\sigma = \sqrt{2}/r$
 d) $\sigma = r \cdot 2$

16) ¿Cuál de las siguientes afirmaciones sobre los algoritmos de Canny y Otsu es correcta?

- a) El detector de bordes de Canny no se comporta como un filtro lineal dado que incorpora operaciones no lineales como thresholding, hysteresis y non-maxima suppression.
- b) El umbral óptimo en el algoritmo de Otsu se obtiene minimizando la varianza inter-clase o maximizando la varianza intra-clase.
- c) En el algoritmo de Canny obtendremos bordes más discontinuos/fragmentados si reducimos el umbral bajo. *→ Hay más candidatos ⇒ bordes más continuos.*
- d) Las tres respuestas anteriores son correctas.

17) ¿Cuántas multiplicaciones (ignorando bias) están involucradas en el cálculo del siguiente módulo Inception? Todas las convoluciones se realizan con stride=1 y padding='same' (es decir, las dimensiones espaciales (alto, ancho) a la salida son las mismas que a la entrada). Del mismo modo, la capa de pooling (3x3 pool) emplea un padding que hace que se mantengan las dimensiones del volumen de entrada que recibe.



a) ~1417M

b) ~854M

c) ~271M

d) Ninguna de las anteriores.

- 18) En la aproximación de Bag of Visual Words, a la hora de generar el vocabulario visual, las imágenes se representan como histogramas de frecuencias en donde se intenta reducir el peso de aquellas palabras que aparecen muy frecuentemente. Para ello, se emplea un sistema de ponderación llamado TF-IDF (Term Frequency – Inverse Document Frequency). En dicha ponderación hay cuatro componentes: n_{wl} que representa el número de ocurrencias de la palabra visual w en la imagen I , n_l que representa el número de palabras visuales en la imagen I , N que representa el número total de imágenes en nuestro conjunto de datos (corpus), y n_w que representa el número de imágenes que contienen la palabra visual w . Encuéntrense las correspondencias adecuadas para completar la expresión matemática de la TF-IDF:

$$TF - IDF(w, I) = \frac{A}{B} \log \frac{C}{D} = \frac{n_{wl}}{n_l} \log \frac{N}{n_w}$$

- a) ☒ A= n_{wl} B= n_l C= N D= n_w
- b) A= n_l B= n_{wl} C= n_w D= N
- c) A= N B= n_w C= n_{wl} D= n_l
- d) A= n_w B= N C= n_l D= n_{wl}
- 19) ¿Cuál sería la dimensionalidad del espacio de parámetros si quisiésemos detectar un objeto arbitrario con la Generalized Hough Transform incorporando también rotación y escalado no uniforme?
- a) 2
- b) 3
- c) 4
- d) ☒ 5
- (x_c, y_c, θ, S, p), donde p es el factor de escalado en cada paso.*
- 20) Imaginemos una pirámide Gaussiana, en donde, antes de submuestrear, no hemos aplicado suavizado Gaussiano. A partir de dicha pirámide construimos una pirámide Laplaciana. ¿Es posible reconstruir a la perfección la imagen original a partir de dicha pirámide Laplaciana? Nos referimos a error de reconstrucción 0.0 empleando RMSE entre la imagen original y redondeando al entero más próximo la imagen reconstruida (tal y como hicimos en la práctica 1 de la asignatura).
- a) No. El suavizado previo al submuestreo es imprescindible para construir correctamente la pirámide Laplaciana y ser capaces de reconstruir la imagen original.
- b) ☒ Sí, se puede reconstruir la imagen original a la perfección igualmente. *→ Sumas y restas las mismas cantidades*
- c) No. Solo es posible reconstruirla si se emplea la interpolación adecuada en la construcción de la pirámide Laplaciana.
- d) No. Solo es posible reconstruirla si se emplea interpolación bilineal en la construcción de la pirámide Laplaciana y en la reconstrucción de la imagen a partir de la pirámide Laplaciana.