

VC – Convocatoria Ordinaria

Curso 2025-26

Indicaciones Generales

Esta prueba consiste en un examen tipo test con 20 preguntas. Tan solo se puede marcar una respuesta para cada una. Y dicha respuesta se marcará con una cruz en el formulario que se encuentra en la página siguiente. Es muy importante que el alumnado marque con claridad la respuesta que considera correcta, y no se equivoque al marcarla, dado que lo único que se empleará para la evaluación son las respuestas marcadas en el formulario de la página siguiente.

Las preguntas correctas suman 1 punto. Las incorrectas descuentan 0.333 (es decir, tres preguntas mal descuentan una bien). La pregunta se puede dejar en blanco y ni sumará ni restará puntos. En cualquier caso, la calificación mínima que se puede obtener en esta prueba es 0.



ugr

Universidad de Granada
Departamento de Ciencias de la Computación
e Inteligencia Artificial

Nombre y Apellidos:

DNI:

Formulario de respuestas

Utilice bolígrafo negro o azul para marcar la respuesta que considera correcta (a-d) para cada una de las preguntas (1-20) formuladas:



PREGUNTA	a	b	c	d
1				
2				
3				
4				
5				
6				
7				
8				
9				
10				
11				
12				
13				
14				
15				
16				
17				
18				
19				
20				



ugr

Universidad de Granada
Departamento de Ciencias de la Computación
e Inteligencia Artificial

1) ¿Cuál sería la dimensionalidad del espacio de parámetros si quisiésemos detectar un objeto arbitrario con la *Generalized Hough Transform* incorporando también rotación y escalado no uniforme?

- a) 3
- b) 4
- c) 5
- d) 6

Comentado [PM1]: Tendríamos 5: xc, yc, sx, sy, y rotación.

Recordemos que "escalado no uniforme" significa que no se amplía o reduce la imagen por el mismo factor en x y en y

2) ¿Cuál de las siguientes afirmaciones es correcta?

- a) Para calcular una homografía nos basta con detectar 4 *keypoints*.
- b) Una transformación afín es una matriz 3x3 en donde la fila de abajo es [0,0,1], y la traslación se modela en las dos primeras filas de la tercera columna.
- c) Una homografía relaciona dos imágenes de cualquier escena 3D, siempre y cuando la posición de la cámara haya sufrido solamente un movimiento de rotación o traslación.
- d) Todas las anteriores son incorrectas.

Comentado [PM2]: Falso. Son 4 puntos en correspondencia. Es decir, en todo caso, 8 keypoints (4 en cada imagen).

Véase https://pradogrado2526.ugr.es/pluginfile.php/243169/mod_folder/content/0/P3.pdf (slides 90-93)

Comentado [PM3]: Esta es la única correcta. Véase slide 83 de https://pradogrado2526.ugr.es/pluginfile.php/243169/mod_folder/content/0/P3.pdf

Comentado [PM4]: No es verdad. Debería ser solamente un movimiento de rotación.

Véase https://pradogrado2526.ugr.es/pluginfile.php/243169/mod_folder/content/0/P3.pdf (slides 77 y 81)

3) Imaginemos que disponemos de un volumen de entrada de tamaño ImageNet (224x224x3) y estamos trabajando con AlexNet (arquitectura presentada en el artículo *Krizhevsky, Sutskever & Hinton. "ImageNet classification with deep convolutional neural networks" (NIPS, 2012)*, y una de las principales causas originales del auge actual de Deep Learning). Si ahora realizamos la convolución, tal y como se hace en el artículo original, con 96 filtros 11x11, con padding=0 y stride=4. ¿Cuáles serán las dimensiones del volumen de salida tras este primer bloque convolucional?

- a) 96x53x53
- b) 96x54x54
- c) 96x55x55
- d) Ninguno de los anteriores

Comentado [PMS5]: $\text{Output_size} = ((N+2 \cdot P - F) / \text{stride}) + 1$

$(224+0-11)/4 + 1 = 213/4 + 1 = 53.25 + 1 = 54.25 \rightarrow 54$ (hay que redondear hacia abajo)

O, usando la otra técnica que mencioné en clase: $224-11 = 213 \rightarrow 213/4 = 53.25 \rightarrow$ redondeando hacia arriba 54

Véase https://pradogrado2526.ugr.es/pluginfile.php/243159/mod_folder/content/0/4_dudas.pdf (slides 10-52)

4) Imaginemos que estamos en el contexto de SIFT y, partiendo de una imagen con $\sigma_{ini} = 0.8$, hacemos *upsampling* (duplicando el número de filas y columnas), y luego suavizamos con una Gaussiana con $\sigma = 1$. A continuación, la imagen resultante de esa operación la suavizamos con una Gaussiana con $\sigma = 1.5$. Y, finalmente, hacemos *downsampling* (reduciendo a la mitad el número de filas y columnas). ¿Cuál sería el sigma equivalente final? Es decir, ¿cuál sería el sigma de la imagen resultante de todas estas operaciones?

- a) ≈ 1.21
- b) ≈ 3.69
- c) ≈ 1.97
- d) Ninguna de las anteriores

Comentado [PM6]: CORRECTO.

$\sqrt{(0.8^2 \cdot 2 + (1^2 \cdot 2 + (1.5^2 \cdot 2)) / 2}$

Véase slides 14-17 de https://pradogrado2526.ugr.es/pluginfile.php/243158/mod_folder/content/0/3.4.Harris_SIFT_HOG.pdf



5) ¿Cuál de las siguientes afirmaciones, relativas a las pirámides Laplacianas y Gaussianas, es correcta?

- a) Si no empleamos suavizado a la hora de generar la pirámide Gaussiana no podremos reconstruir a la perfección la imagen de entrada (a partir de la Laplaciana).
- b) La calidad de la reconstrucción de la imagen original a partir de la pirámide Laplaciana depende del sigma empleado en la construcción de la pirámide Gaussiana.
- c) En cada nivel (salvo la cima), la pirámide Laplaciana se obtiene restando a un nivel gaussiano una versión más suavizada del mismo nivel, lo que produce una imagen que conserva principalmente los detalles (altas frecuencias).
- d) Todas las anteriores son incorrectas.


Comentado [PM7]: Como hemos visto en la P1, si se puede reconstruir perfectamente la imagen original de entrada sin emplear suavizado en la pirámide Gaussiana

Comentado [PM8]: Esto sabemos que no es verdad. Véase slides 81-85 de https://pradogrado2526.ugr.es/pluginfile.php/243164/mod_folder/content/0/Assignment1.pdf

Comentado [PM9]: CORRECTA

Lo que estamos diciendo aquí es que cada nivel de la Laplaciana (salvo la cima de la pirámide; la imagen más pequeña de arriba de todo) se obtiene como una diferencia de Gaussianas, en donde a cada nivel de la pirámide Gaussiana se le resta una versión del mismo nivel (es decir, misma resolución) más suavizada. No se dice que dicha versión suavizada se obtenga suavizando directamente, con un kernel Gaussiano, el nivel de la Gaussiana. En otras palabras, no entramos en cómo se ha obtenido esa "versión más suavizada del mismo nivel". Nosotros sabemos que se obtiene suavizando la imagen del nivel, submuestreando y, luego, haciendo upsampling (lo cual incluye suavizado). Y esa nueva imagen generada por la expansión está más suavizada que la del mismo nivel de la pirámide Gaussiana.

6) En base a las curvas de entrenamiento que se muestran a continuación (en el eje Y se muestra la función de pérdida; en el eje X se muestran las épocas), ¿cuál de las siguientes interpretaciones considera más pertinente y plausible?



- a) Estamos presenciando un fenómeno de sobreentrenamiento, en donde las curvas de entrenamiento y validación, cada vez, se van separando más.
- b) El *learning rate* seguramente sea demasiado elevado, motivo por el cual la curva de validación fluctúa demasiado.
- c) El comportamiento que observamos es probablemente debido al uso de medias móviles en *batch normalization*.
- d) Estamos aplicando un *data augmentation* excesivamente agresivo sobre el conjunto de entrenamiento.

Comentado [PM10]: El sobreentrenamiento tendría lugar, en todo caso, si el entrenamiento fuese mejor que validación.

Comentado [PM11]: Si uno quiere saber si el learning rate es demasiado alto, principalmente, mira la curva de entrenamiento. Y, en este caso, la curva de entrenamiento no oscila de forma particularmente dramática.

Comentado [PM12]: CORRECTO.

Esto hace que el entrenamiento avance lentamente, y que los resultados en validación oscilen y sean mejores que los de entrenamiento. Es decir, estamos intentando entrenar con ejemplos tan difíciles que aprendemos despacio, y nuestra validación es mejor que nuestro entrenamiento (las imágenes de validación son más fáciles que las del propio entrenamiento).

Véase <https://pradogrado2526.ugr.es/mod/forum/discuss.php?d=33631>



ugr

Universidad de Granada

Departamento de Ciencias de la Computación
e Inteligencia Artificial

7) ¿Cuál de las siguientes afirmaciones, relativas al entrenamiento de modelos profundos, es correcta?

- a) La combinación de *learning rate* elevado y *momentum* elevado puede resultar problemática, dado que puede provocar que diverja el entrenamiento.
- b) La *one-cycle policy* de Leslie N. Smith, implica primero disminuir el *learning rate* en las primeras épocas, mientras aumenta el *momentum* y, llegado un punto, realizar el proceso inverso: progresivamente aumentar el *learning rate* y disminuir el *momentum*.
- c) La *one-cycle policy* de Leslie N. Smith, por defecto, se aplica varias veces durante todo el entrenamiento. Es decir, como tal, hay varios *one-cycle* durante el entrenamiento.
- d) Todas las anteriores son correctas.

Comentado [PM13]: Esta es la correcta.

Comentado [PM14]: No es correcto. Véase slide 45 de https://pradogrado2526.ugr.es/pluginfile.php/243166/mod_folder/content/0/P2.pdf

Comentado [PM15]: No es correcto. Véase slide 45 de https://pradogrado2526.ugr.es/pluginfile.php/243166/mod_folder/content/0/P2.pdf

8) A nivel teórico, ¿cómo funciona *dropout* (con probabilidad p ; siendo p la probabilidad de apagar/eliminar una unidad) en tiempo de inferencia? Se asume que no se usa *inverted dropout*, empleado frecuentemente en las implementaciones existentes de *dropout*.

- a) En inferencia, la unidad está siempre presente y los pesos se dividen por p .
- b) En inferencia, la unidad está siempre presente y los pesos se dividen por $1-p$.
- c) En inferencia, la unidad está siempre presente y los pesos se multiplican por p .
- d) En inferencia, la unidad está siempre presente y los pesos se multiplican por $1-p$.

Comentado [PM16]: CORRECTA.

Como la probabilidad p es de "eliminar la unidad" (*not keeping it*), tenemos que multiplicar por $1-p$.

Lo que se ve en la slide 30 de https://pradogrado2526.ugr.es/pluginfile.php/243159/mod_folder/content/0/4.2.DL_quizzes.pdf es la probabilidad de "quedarte con una unidad" (*keeping it*)



ugr

Universidad de Granada

Departamento de Ciencias de la Computación
e Inteligencia Artificial

9) ¿Cuántos pesos (parámetros entrenables), incluyendo *bias*, tiene la siguiente red convolucional? Lo que en la tabla aparece con “???” también debe ser calculado a la hora de resolver el ejercicio.

Layer Type	Kernel Size	Input Output dimensions	Input Output channels
Conv	3x3	224x224 224x224	3 128
ReLU	-	224x224 224x224	-
BN	-	224x224 224x224	-
MaxPooling	2x2	224x224 112x112	-
Conv	3x3	112x112 112x112	128 64
ReLU	-	112x112 112x112	-
BN	-	112x112 112x112	-
MaxPooling	2x2	112x112 56x56	-
Conv	3x3	56x56 56x56	64 32
ReLU	-	56x56 56x56	-
BN	-	56x56 56x56	-
MaxPooling	2x2	56x56 28x28	-
FC	-	??? 256	-
ReLU	-	256 256	-
BN	-	256 256	-
Dropout	-	256 256	-
FC	-	256 128	-
ReLU	-	128 128	-
BN	-	128 128	-
FC	-	128 50	-

- a) 6559186
b) 6465586
c) 6560402
d) Ninguno de los anteriores

Comentado [PM17]: CORRECTO.

$(3 \cdot 3 + 1) \cdot 128 + 128 \cdot 2 + (3 \cdot 3 + 1) \cdot 64 + 64 \cdot 2 + (3 \cdot 3 + 1) \cdot 32 + 32 \cdot 2 + 25088 \cdot 256 + 256 + 256 \cdot 2 + 256 \cdot 128 + 128 + 128 \cdot 2 + 128 \cdot 50 + 50$

SI SE QUIERE PROBAR CON UN PEQUEÑO CODIGO:

path = untar_data(URLs.IMAGENETTE_160)

```
CIFAR_25 = DataBlock(
    blocks=(ImageBlock, CategoryBlock),
    get_items=get_image_files,
    splitter=RandomSplitter(valid_pct=0.1, seed=42),
    get_y=parent_label,
    item_tfms = Resize(224), batch_tfms = [IntToFloatTensor(),
    Normalize()])
```

dls = CIFAR_25.dataloaders(path/'train', bs=128, n=1000)

```
BaseNet = sequential(
    nn.Conv2d(in_channels=3, out_channels=128, kernel_size=(3,3), stride=(1,1), padding='same'), nn.ReLU(), nn.BatchNorm2d(128),
```

```
nn.MaxPool2d(kernel_size=(2,2)),
```

```
nn.Conv2d(in_channels=128, out_channels=64, kernel_size=(3,3), stride=(1,1), padding='same'), nn.ReLU(), nn.BatchNorm2d(64),
```

```
nn.MaxPool2d(kernel_size=(2,2)),
```

```
nn.Conv2d(in_channels=64, out_channels=32, kernel_size=(3,3), stride=(1,1), padding='same'), nn.ReLU(), nn.BatchNorm2d(32),
```

```
nn.MaxPool2d(kernel_size=(2,2)),
```

```
nn.Flatten(),
nn.Linear(in_features=25088,
out_features=256), nn.ReLU(), nn.BatchNorm1d(256),
```

```
nn.Dropout(0.5),
```

```
nn.Linear(in_features=256,
out_features=128), nn.ReLU(), nn.BatchNorm1d(128),
nn.Linear(in_features=128, out_features=50),
)
```

```
def count_parameters(model): return sum(p.numel() for p in
model.parameters() if p.requires_grad)
print(count_parameters(BaseNet))
print(total_params(BaseNet))
```

```
learn = Learner(dls, BaseNet)
learn.summary()
```

Comentado [PM18]: Este sería el resultado de no contabilizar bien la profundidad de los filtros: $(3 \cdot 3 + 1) \cdot 128 + 128 \cdot 2 + (3 \cdot 3 + 1) \cdot 64 + 64 \cdot 2 + (3 \cdot 3 + 1) \cdot 32 + 32 \cdot 2 + 25088 \cdot 256 + 256 + 256 \cdot 2 + 256 \cdot 128 + 128 + 128 \cdot 2 + 128 \cdot 50 + 50$

Comentado [PM19]: Este es el resultado de no contabilizar bien el BN. En lugar de 2 pesos por canal y BN capa, se añaden 4 (es decir, estamos incluyendo también la media y la std).

$(3 \cdot 3 + 1) \cdot 128 + 128 \cdot 4 + (3 \cdot 3 + 1) \cdot 64 + 64 \cdot 4 + (3 \cdot 3 + 1) \cdot 32 + 32 \cdot 4 + 25088 \cdot 256 + 256 + 256 \cdot 4 + 256 \cdot 128 + 128 + 128 \cdot 4 + 128 \cdot 50 + 50$



10) ¿Cuál de las siguientes afirmaciones es correcta?


- a) A mayor número de ejemplos de entrenamiento, el error de entrenamiento tiende a subir y el de test (*out-of-sample error*) a disminuir.
- b) A mayor número de parámetros, el error de entrenamiento tiende a disminuir, mientras que el de test disminuye pero luego aumenta (lo que se conoce como sobreajuste).
- c) Con modelos sobreparametrizados, teóricamente, cuando se entrena el tiempo suficiente, el rendimiento fuera de la muestra primero aumenta, luego decrece y, finalmente, aumenta de nuevo.
- d) Todas las anteriores son correctas.

Comentado [PM20]: Véase slide 28 en https://pradograde2526.ugr.es/pluginfile.php/243158/mod_folder/content/0/3.1.IntroToMachineLearning_quizzes.pdf

Comentado [PM21]: Véase slides 53 y 54 de https://pradograde2526.ugr.es/pluginfile.php/243159/mod_folder/content/0/4.2.DL_quizzes.pdf

Comentado [PM22]: CORRECTA

11) En la figura de abajo se puede ver cómo se pasa de un volumen $28 \times 28 \times 192$ a un volumen $28 \times 28 \times 32$. En el primer caso, (i), no se emplean convoluciones 1×1 , sino que se emplean 32 filtros 5×5 en modo “same”. En el segundo, (ii), sí se emplean. Deben calcularse el número de multiplicaciones que se realizan en (i) y en (ii), y calcular ese *ratio*. ¿Cuál es la ganancia (o pérdida), en número de multiplicaciones, cuando se utilizan convoluciones 1×1 y cuando no?



- a) La versión sin convoluciones 1×1 tiene ~11.68 veces más multiplicaciones que la versión con convoluciones 1×1 .
- b) La versión con convoluciones 1×1 tiene ~11.68 veces más multiplicaciones que la versión sin convoluciones 1×1 .
- c) Ambas tienen el mismo número de multiplicaciones.
- d) Ninguna de las anteriores.

Comentado [PM23]: CORRECTO.

$5 \times 5 \times 192 \times 28 \times 28 \times 32 / (192 \times 28 \times 28 \times 16 + 5 \times 5 \times 16 \times 28 \times 28 \times 32)$

La versión sin convoluciones 1×1 tiene ~9.68 veces más multiplicaciones que la versión con convoluciones 1×1 .



ugr

Universidad de Granada

Departamento de Ciencias de la Computación e Inteligencia Artificial

12) Si trabajamos con el dominio de la frecuencia, ¿qué efecto tiene aplicar un filtro paso-bajo a una imagen? Más concretamente, ¿qué ocurre tras aplicar suavizado Gaussiano?

- Realza las altas frecuencias presentes en la imagen (correspondientes a los niveles de intensidad lejanos al centro de la imagen de Fourier).
- Reduce el ruido y, como consecuencia, atenúa las frecuencias presentes en torno al centro de la imagen de Fourier.
- Reduce el ruido y, como consecuencia, atenúa frecuencias lejanas al centro de la imagen de Fourier.
- Reduce el ruido y, como consecuencia, elimina completamente todas las altas frecuencias (correspondientes a niveles de intensidad lejanos al centro de la imagen de Fourier).

Comentado [PM24]: El suavizado no realza altas frecuencias. Busca eliminarlas. Por eso se llama filtro paso-bajo

Comentado [PM25]: El ruido son altas frecuencias, y estas no se muestran en la parte central de la imagen de Fourier. Véase https://pradogrado2526.ugr.es/pluginfile.php/243157/mod_folder/content/0/2.3.FourierAnalysis_in_Images.pptx o slides 46-52 de https://pradogrado2526.ugr.es/pluginfile.php/243157/mod_folder/content/0/2.3.Pyramids.pdf

Comentado [PM26]: CORRECTA.

Lo máximo que podemos hacer es atenuar el ruido (frecuencias lejanas en relación al centro de la imagen de Fourier). Y esto es cierto, tanto a nivel teórico como práctico. A nivel teórico, una Gaussiana ideal es infinita, de modo que nunca llegamos a tener un cero exactamente con el que multiplicar nuestra señal. Pero, a nivel práctico, nuestros kernels discretos equivalen a multiplicar una Gaussiana con una señal rectangular. Y eso resulta que equivale a convolucionar en el dominio de la frecuencia una Gaussiana con una función sinc, con lo que, como tal, no es que vayamos a anular completamente todas las frecuencias elevadas.

La única opción de eliminar completamente las altas frecuencias (por encima de una frecuencia de corte), y esto solo es válido a nivel teórico, sería convolucionar con una función sinc (cuya transformada de Fourier es una señal rectangular).

Comentado [PM27]:

LBP: sí (histograma de códigos LBP).
BoW: sí (histograma de palabras visuales).
HOG: sí (histogramas de orientaciones).
SIFT: sí (histogramas de orientaciones).
Haralick: no (vector de estadísticos derivados de la GLCM, no un histograma como descriptor final).
Harris Corner Detector: no (es un detector basado en la SSM; no emplea histogramas).

13) ¿Cuántos de los siguientes métodos no emplean una representación basada en histogramas: *Local Binary Patterns (LBP)*, *Bag of Words (BoW) Model*, *Histogram of Oriented Gradients (HOG)*, *Haralick Texture Features*, *Harris Corner Detector*, y *Scale-Invariant Feature Transform (SIFT)*?

- 0
- 1
- 2
- 3

14) Consideremos la siguiente imagen de 5x5 píxeles, y el siguiente kernel 3x3. ¿Cuál sería el resultado de convolucionar la imagen 5x5 con el kernel 3x3 en modo *valid*, usando *zero-padding* en caso de ser necesario, y con *stride* 2?

0	1	1	2	1
2	3	3	3	1
5	5	5	5	1
6	6	6	6	1
6	6	6	6	6

-1	-2	-1
0	0	0
1	2	1

(a)	(b)	(c)	(d)																										
<table><tr><td>17</td><td>10</td></tr><tr><td>4</td><td>8</td></tr></table>	17	10	4	8	<table><tr><td>-17</td><td>-10</td></tr><tr><td>-4</td><td>-8</td></tr></table>	-17	-10	-4	-8	<table><tr><td>7</td><td>12</td><td>5</td></tr><tr><td>11</td><td>12</td><td>3</td></tr><tr><td>-18</td><td>-24</td><td>-8</td></tr></table>	7	12	5	11	12	3	-18	-24	-8	<table><tr><td>-7</td><td>-12</td><td>-5</td></tr><tr><td>-11</td><td>-12</td><td>-3</td></tr><tr><td>18</td><td>24</td><td>8</td></tr></table>	-7	-12	-5	-11	-12	-3	18	24	8
17	10																												
4	8																												
-17	-10																												
-4	-8																												
7	12	5																											
11	12	3																											
-18	-24	-8																											
-7	-12	-5																											
-11	-12	-3																											
18	24	8																											

Comentado [PM28]: La B es la correcta. Las dos claves de este ejercicio son: tener claro que en la convolución hay que rotar el kernel; y que convolución en modo valid implica que no hace falta padding (por lo que la información en relación al zero-padding no nos hace falta)

La A es como la B, pero si se hace correlación. La C es el resultado de aplicar correlación "same". La D es el resultado de aplicar convolución "same".



ugr

Universidad de Granada
Departamento de Ciencias de la Computación
e Inteligencia Artificial

15) En el contexto de *template matching*, ¿cuál de las siguientes afirmaciones es correcta?

- Normalizar el *template* restándole su valor medio (*zero-mean template*) proporciona invarianza a *offsets* aditivos de intensidad (del estilo $F = H + \beta$, siendo F el *image patch*, H el *template*, y β el *offset* añadido).
- La *Normalized Cross-Correlation* (NCC), cuya expresión matemática (en caso de que el alumnado no la recuerde) es
$$NCC[i, j] = \frac{\sum_{u=-k}^k \sum_{v=-k}^k (H[u, v] - \bar{H})(F[i+u, j+v] - \bar{F})}{\sqrt{\sum_{u=-k}^k \sum_{v=-k}^k (H[u, v] - \bar{H})^2 \sum_{u=-k}^k \sum_{v=-k}^k (F[i+u, j+v] - \bar{F})^2}}$$
, es invariante a transformaciones afines en la intensidad (del estilo $F = \alpha H + \beta$), salvo por el signo de α .
- La suma de diferencias al cuadrado (SSD) se puede implementar con filtros lineales.
- Todas las anteriores son correctas.

Comentado [PM29]: Véase slides 23-30 de https://pradograde2526.ugr.es/pluginfile.php/243158/mod_folder/content/0/3.2.TemplateMatching_Texture.pdf

Comentado [PM30]: Véase slide 38 de https://pradograde2526.ugr.es/pluginfile.php/243158/mod_folder/content/0/3.2.TemplateMatching_Texture.pdf

El tema del signo de alpha viene determinado solamente por el siguiente hecho: imaginemos que tenemos nuestro template t ; y también tenemos un *image patch* $p = \alpha t + \beta$. NCC acabaría siendo $\alpha / |\alpha|$.
Si $\alpha > 0 \rightarrow NCC = 1$.
Si $\alpha < 0 \rightarrow NCC = -1$.
Por eso se dice que es invariante a transformaciones afines de intensidad salvo por el signo de alpha.

Comentado [PM31]: Correcto.

Véase slide 37 en https://pradograde2526.ugr.es/pluginfile.php/243158/mod_folder/content/0/3.2.TemplateMatching_Texture.pdf La SSD se puede calcular como una constante (H^2) menos 2 veces la correlación de H y F , más la correlación de F^2 y un kernel de unos. Véase también pregunta 10 en https://pradograde2526.ugr.es/pluginfile.php/243171/mod_resource/content/3/Examen_TipoA.pdf

Comentado [PM32]: CORRECTA.

Comentado [PM33]: CORRECTA.

El III no lo es, dado que es una Laplaciana y, como sabemos, se puede descomponer como la suma de dos convoluciones separables. Por lo tanto, no es una separabilidad directa. Véase slides 72-76 de https://pradograde2526.ugr.es/pluginfile.php/243157/mod_folder/content/0/2.2.GaussianFilters_Edges.pdf Véase también slides 58-64 de https://pradograde2526.ugr.es/pluginfile.php/243164/mod_folder/content/0/Assignment1.pdf

La descomposición de los otros kernels se puede encontrar en slides 63 y 22 de https://pradograde2526.ugr.es/pluginfile.php/243157/mod_folder/content/0/2.2.GaussianFilters_Edges.pdf

Comentado [PM34]: Esto es correcto. Viene, tal cual, de la teoría de BoW. Véase slide 39: https://pradograde2526.ugr.es/pluginfile.php/243158/mod_folder/content/0/3.3.BoW_Blobs.pdf

Comentado [PM35]: Correcto también. Véase slides 33 y 34: https://pradograde2526.ugr.es/pluginfile.php/243158/mod_folder/content/0/3.3.BoW_Blobs.pdf

Comentado [PM36]: Correcto también. Véase slides 32-45 https://pradograde2526.ugr.es/pluginfile.php/243158/mod_folder/content/0/3.3.BoW_Blobs.pdf

Comentado [PM37]: CORRECTA

16) ¿Cuáles de los siguientes kernels 2D son directamente separables en dos únicos kernels 1D?

$$(I) \quad \frac{1}{8} \begin{bmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{bmatrix} \quad (II) \quad \frac{1}{16} \begin{bmatrix} 1 & 2 & 1 \\ 2 & 4 & 2 \\ 1 & 2 & 1 \end{bmatrix}$$

$$(III) \quad \begin{bmatrix} 0 & -1 & 0 \\ -1 & 4 & -1 \\ 0 & -1 & 0 \end{bmatrix} \quad (IV) \quad \frac{1}{9} \begin{bmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{bmatrix}$$

- (I), (II) y (IV) son directamente separables en dos kernels 1D.
- Todos los kernels lo son.
- (II) y (IV) son directamente separables en dos kernels 1D.
- Solo los kernels (I) y (II) son directamente separable en dos kernels 1D.

17) ¿Cuál de las siguientes afirmaciones en relación a Bag of Words (BoW) es correcta?

- El sistema de ponderación llamado TF-IDF (*Term frequency - Inverse document frequency*) empleado en BoW está acotado entre 0 y $\log(N)$, siendo N el número total de imágenes en nuestro conjunto de datos (corpus). En caso de que el alumnado no recuerde la expresión matemática, sería esta: $TF - IDF(w, I) = \frac{n_{wI}}{n_I} \log \frac{N}{n_w}$, con n_{wI} el número de ocurrencias de la palabra w en la imagen I , n_I el número total de palabras en la imagen I , y n_w el número de imágenes que contienen la palabra w .
- La extracción de características se puede llevar a cabo tanto a partir de puntos de interés (*sampling* selectivo) como a partir de características densas (*sampling* uniforme).
- El paso que sigue a la extracción de características en el proceso de BoW es la generación del vocabulario visual.
- Todas las anteriores son correctas.



18) Partimos de un modelo preentrenado en el *dataset A* (con imágenes de tamaño 224x224 y 10 clases de salida, en donde el preprocesado ha consistido en estandarizar los datos de entrada, es decir, para cada imagen, restar la media del *dataset* y dividir por la desviación típica). Con dicho modelo, queremos abordar la clasificación de imágenes del *dataset B* (con imágenes de tamaño 128x128 y 5 clases de salida). Si queremos hacer un breve *fine-tuning* con las imágenes del *dataset B*, ¿cuál sería el proceso estándar a seguir?

- a) Solo sería necesario adaptar la capa final, ajustándonos a la nueva tarea que queremos resolver, pasando de 10 unidades de salida a 5.
- b) Tendríamos que adaptar la capa final, ajustándonos a la nueva tarea que queremos resolver, pasando de 10 unidades de salida a 5, y luego tendríamos que reescalar las imágenes del *dataset B* al tamaño del *dataset A*.
- c) Tendríamos que adaptar la capa final, ajustándonos a la nueva tarea que queremos resolver, pasando de 10 unidades de salida a 5. Luego, debemos reescalar las imágenes del *dataset B* al tamaño del *dataset A*, y preprocesar las imágenes estandarizando con las estadísticas del *dataset A*.
- d) Tendríamos que adaptar la capa final, ajustándonos a la nueva tarea que queremos resolver, pasando de 10 unidades de salida a 5. Luego, debemos reescalar las imágenes del *dataset B* al tamaño del *dataset A*, y preprocesar las imágenes estandarizando con las estadísticas del *dataset B*.

19) En el contexto del algoritmo de detección de bordes de Canny, ¿cuál de las siguientes afirmaciones es correcta?

- a) Si disminuimos el umbral bajo y aumentamos el sigma del filtro de derivadas de la Gaussiana, posiblemente detectaremos más bordes "finos".
- b) En el algoritmo de Canny se define un proceso de *hysteresis* que nos permite obtener bordes de 1 píxel de ancho.
- c) La orientación del gradiente es perpendicular al borde, y esta información se emplea para realizar la supresión de no máximos.
- d) Las tres respuestas anteriores son erróneas.

Comentado [PM38]: CORRECTO

a) Incorrecta: falta adaptar el tamaño de entrada (128 ≠ 224) y mantener el preprocesado esperado.

b) Incorrecta: aquí redimensionamos bien, pero no garantizamos que la distribución de entrada coincida con la que el modelo espera (normalización de A).

d) Incorrecta "como proceso estándar": normalizar con estadísticas de B introduce un shift respecto al entrenamiento original. Puede funcionar en algunos casos si reentrenas bastante o si recalibras todo de alguna manera, pero no es lo estándar para un "breve fine-tuning".

Es algo parecido (no exactamente lo mismo) a lo que vimos en slide 38 de

https://pradogrado2526.ugr.es/pluginfile.php/243158/mod_folder/content/0/3.1.IntroToMachineLearning.pdf y slide 25 de https://pradogrado2526.ugr.es/pluginfile.php/243158/mod_folder/content/0/3.1.IntroToMachineLearning_quizzes.pdf

En general, lo que se suele hacer es preprocesar los datos (incluyendo el escalado) tal y como fue entrenado el modelo base. Es decir, como regla general, la práctica estándar en transfer learning es:

- emplear el mismo tamaño de entrada que el modelo base (p. ej. 224x224) porque la arquitectura y los pesos están ajustados a esa escala de contenido.

- emplear la misma normalización (media y desviación del dataset con el que se preentrenó, o el escalado "oficial" del backbone que sea), para que las activaciones internas queden en el rango/distribución esperada.

Si normalizamos con μ_B y σ_B estamos cambiando la escala y el centrado de los píxeles que "ve" el modelo y las primeras capas producirán/recibirán activaciones con un shift respecto a lo aprendido. Otra cosa es si vamos a fine-tunear muchas capas (o todo el modelo) durante suficiente tiempo, o si queremos "adaptar" el modelo a la nueva distribución desde cero. Pero eso no es lo que se indica en el enunciado.

Comentado [PM39]: Esta no es correcta porque aumentar el sigma implica detectar bordes más gruesos, no más finos. Véase, por ejemplos, slide 94 de

https://pradogrado2526.ugr.es/pluginfile.php/243157/mod_folder/content/0/2.2.GaussianFilters_Edges.pdf

Comentado [PM40]: Los bordes de 1 píxel se logran con la supresión de no-máximos (Non-Maximum Suppression). La histéresis sirve para conectar/filtrar bordes usando dos umbrales (fuerte/débil). Véase slides 88-92 en

https://pradogrado2526.ugr.es/pluginfile.php/243157/mod_folder/content/0/2.2.GaussianFilters_Edges.pdf

Comentado [PM41]: CORRECTA

Véase slide 88 en

https://pradogrado2526.ugr.es/pluginfile.php/243157/mod_folder/content/0/2.2.GaussianFilters_Edges.pdf



ugr

Universidad de Granada

Departamento de Ciencias de la Computación
e Inteligencia Artificial

20) Imaginemos que tenemos un kernel Gaussiano 5×5 , y queremos suavizar 10 veces una imagen con este kernel. Si seguimos todas las convenciones explicadas en clase (como el hecho de discretizar kernels cubriendo, al menos, 3σ), ¿Cuál sería el tamaño del kernel necesario para producir el efecto de suavizado equivalente con una única convolución?

- a) 13×13
- b) 15×15
- c) 17×17
- d) 41×41

Comentado [PM42]: CORRECTA.

Aquí se buscaba resolver el ejercicio de la misma manera en que se propuso en clase (slide 16 de https://pradograde2526.ugr.es/pluginfile.php/243157/mod_folder/content/0/2.2.GaussianFilters_Edges.pdf). Y, más concretamente, como hablamos de nivel de "suavizado equivalente", tendríamos que hacer algo como lo mostrado en https://pradograde2526.ugr.es/pluginfile.php/243157/mod_folder/content/0/2_dudas.pdf (slides 60 y 61). En realidad, este ejercicio era idéntico en forma y fondo a este último.

$T=2k+1 = 5 \rightarrow k=2$
 $3 \cdot \sigma = 2 \rightarrow \sigma = 0.6666667$
 $\sigma_{total} = \sigma_{ini} \cdot \sqrt{N} = 0.6666667 \cdot \sqrt{10} = 2.11$

$3 \cdot \sigma_{total} = 3 \cdot 2.11 = 6.32$ Ahora hay que redondear hacia arriba porque, tal y como nos indica el enunciado, debemos cubrir, "al menos, 3σ ".

Como hay que redondear hacia arriba $k=7 \rightarrow T=15$

Quien obtuvo 41×41 fue tras aplicar la expresión de tamaño de kernel equivalente, pero no la de suavizado equivalente. Véase slides 57-59 de https://pradograde2526.ugr.es/pluginfile.php/243157/mod_folder/content/0/2_dudas.pdf Evidentemente, no es lo mismo. En el mismo ejemplo de las slides, obteníamos un kernel de 25×25 vs uno de 15×15 .



ugr

Universidad de Granada
Departamento de Ciencias de la Computación
e Inteligencia Artificial