



SKIN CANCER DETECTION WITH DEEP LEARNING

Doble Grado de Ingeniería Informática y Matemáticas (DGIIM)
Visión por Computador

Antonio Cantillo Molina
Leandro Jorge Fernández Vega
Jaime Corzo Galdó
Mario Líndez Martínez

Profesores:
Pablo Mesejo Santiago
Siham Tabik Ouled Hrou

Enero 2026





ÍNDICE

1. Introducción
2. Contexto
3. Evolución de arquitecturas en detección de melanomas
4. Métodos
5. Datos y protocolo experimental
6. Resultados
7. Conclusiones


1. Introducción




- El melanoma es el más peligroso: la detección temprana es clave.
- Diagnóstico tradicional: inspección visual + dermatoscopia (componente subjetivo).
- Similitud visual entre lesiones benignas y malignas.
- Desequilibrio de clases: menos melanomas que nevus.
- Objetivo práctico: apoyo a la decisión clínica (no sustitución).

2. Contexto


- **Dermatoscopia:** Técnica de imagen especializada para examinar lesiones cutáneas.



Melanoma



Nevus



Seborrheic Keratosis

3. Evolución de Arquitecturas en Detección de Melanomas

El Estándar Establecido (CNNs)

Benchmark de Arquitecturas [Per21]

- Las CNNs (resNet, DenseNet) se consolidan como el estándar dominante.
- La profundidad es clave: redes profundas capturan mejor las irregularidades sutiles que las superficiales.
- Limitación: Campo receptivo local

Refinamiento Híbrido y Eficiencia

- Fusión de características [Alm20]
- Knowledge Distillation [Ade23]
- Eficiencia (Lightweight) [Ald22]


La Era de los Transformers

- Cambio de Paradigma [Ven24]
- Swin Transformers [Aks24]


[Per21] E. Perez, O. Reyes, and S. Ventura, "Convolutional neural networks for the automatic diagnosis of melanoma: an extensive experimental study," *Medical Image Analysis*, vol. 67, p. 101858, 2021. [Alm20] J.A. Almaraz-Damian et al., "Melanoma and nevus skin lesion classification using handcraft and deep learning feature fusion...", *Entropy*, vol. 22, no. 4, p. 484, 2020. [Ald22] T.H. Aldhyani et al., "Multi-class skin lesion classification using a lightweight dynamic kernel deep-learning-based CNN," *Diagnostics*, vol. 12, no. 9, p. 2048, 2022. [Ade23] A.K. Adepu et al., "Melanoma classification from dermatoscopy images using knowledge distillation for highly imbalanced data," *Computers in Bio. and Med.*, vol. 154, p. 106571, 2023. [Ven24] S.M. Venugopal, "Can vision transformers Be the next state-of-the-art model for oncology medical image analysis?," *AI in Precision Oncology*, vol. 1, no. 6, 2024. [Aks24] S. Aksoy, P. Demircioglu, and I. Bogrekci, "Enhancing melanoma diagnosis with advanced deep learning models focusing on vision transformer, swin transformer...", *Dermatopathology*, vol. 11, no. 3, 2024.

4. Métodos

- Rendimiento en clasificación multiclase




- Rendimiento en clasificación binaria



Métodos: Modelos

• Vision Transformer (ViT)

Scaled Dot-Product Attention



Multi-Head Attention






Figure 1: The Transformer - model architecture.




Photos from:

- shish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. arXiv preprint arXiv:1706.03762, 2017
- Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, et al. An image is worth 16x16 words: Transformers for image recognition at scale. arXiv preprint arXiv:2010.11929, 2020

Métodos: Modelos

- Vision Transformer (ViT) + DINO

Self-distillation with no labels



Segmentation from supervised versus DINO

Supervised



DINO



Photos from: Mathilde Caron, Hugo Touvron, Ishan Misra, Hervé Jégou, Julien Mairal, Piotr Bojanowski, and Armand Joulin. Emerging properties in self-supervised vision transformers. arXiv preprint arXiv:2104.14294, 2021.

Métodos: Modelos

- EfficientNetB4

La familia EfficientNet parte de **EfficientNetB0**.

Este fue obtenido mediante: Neural Architecture Search (NAS) + Reinforcement Learning. Obtener el resto de las redes (B1-B7) se hace a través del **Escalado Compuesto**:

Sea un modelo:

$$\mathcal{N} = \bigodot_{i=1 \dots s} \mathcal{F}_i^{L_i}(X_{\langle H_i, W_i, C_i \rangle})$$

Objetivo:

$$\max_{d, w, r} \quad \text{Accuracy}(\mathcal{N}(d, w, r))$$

$$s. t. \quad \mathcal{N}(d, w, r) = \bigodot_{i=1 \dots s} \hat{\mathcal{F}}_i^{d \cdot \hat{L}_i}(X_{\langle r \cdot \hat{H}_i, r \cdot \hat{W}_i, w \cdot \hat{C}_i \rangle})$$

$$\text{Memory}(\mathcal{N}) \leq \text{target_memory}$$

$$\text{FLOPS}(\mathcal{N}) \leq \text{target_flops}$$

Escalado Compuesto:

$$d = \alpha^\phi, \quad w = \beta^\phi, \quad r = \gamma^\phi$$

$$\alpha \cdot \beta^2 \cdot \gamma^2 \approx 2$$

$$\alpha \geq 1, \beta \geq 1, \gamma \geq 1$$

Photos from:

- Tan, M., & Le, Q. (2019). EfficientNet: Rethinking model scaling for convolutional neural networks. Proceedings of the 36th International Conference on Machine Learning (ICML), 6105-6114.

Métodos: Modelos

- Inception-ResNet-v2

Hace uso de bloques **Inception-ResNet Block**. Este bloque consiste en la combinación de:

- Módulo Inception
- Residual Learning + Residual Scaling





Figure 2. Residual learning: a building block.

- Inception-v1:



- Inception-v2
- Inception-v3
- Inception-v4

Photos from:

- He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 770-778.
- Szegedy, C., Liu, W., Jia, Y., Sermanet, P., Reed, S., Anguelov, D., Erhan, D., Vanhoucke, V., & Rabinovich, A. (2015). Going deeper with convolutions. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 1-9.

5. Datos y Protocolo Experimental

ISIC 2017 Dataset

- **Entrenamiento:**


374 Melanoma, 1372 Nevus y 254 Queratosis Seborreica.

- **Validación:**

30 Melanoma, 78 Nevus y 42 Queratosis Seborreica.

- **Test:**

117 Melanoma, 393 Nevus y 90 Queratosis Seborreica.





5. Datos y Protocolo Experimental

Preprocesamiento de Datos

- Input: Redimensionado a 224 x 224 (bilinear interpolation)
- Normalización: Estadísticas ImageNet (Mean/Std) para estabilidad

Entrenamiento y Optimización

- Data Augmentation
- Estrategia de optimización: One Cycle Policy [Smi19]
- Regularización: Weight Decay

Evaluación Rigurosa

- Strict Hold-out: Set de prueba de 600 imágenes
- Integridad: Aislamiento total (sin data leakage)

[Smi19] L.N. Smith and N. Topin, "Super-convergence: Very fast training of neural networks using large learning rates," in *Proc. SPIE*, vol. 11006, Artificial Intelligence and Machine Learning for Multi-Domain Operations Applications, 2019.



Métricas de Evaluación


Métricas Multiclase:

- Accuracy
- Precision, Recall, F1-Score
- **Macro Average** (Uniforme entre las clases) y **Weighted Average** (Usa pesos para cada clase).
- **MCC (Matthews Correlation Coefficient) y Cohen's Kappa:** Estas dos son métricas que tienen en cuenta el desbalance de clases.

Enfoque Clínico (Melanoma vs. Resto)

- Curva ROC, ROC-AUC score
- Curva Precision-Recall
- Operating Points


6. Resultados. Resultados Multiclase - ViT




Resultados Multiclase - ViT



	Precisión	Recall	F1 score
Melanoma	0.6277	0.5043	0.5592
Nevus	0.8442	0.8550	0.8496
Keratosis Seborreica	0.6019	0.7222	0.6566



Resultados Multiclase - ViT+DINO




Resultados Multiclase - ViT+DINO




	Precisión	Recall	F1 score
Melanoma	0.6591	0.4957	0.5659
Nevus	0.8230	0.8753	0.8483
Keratosis Seborreica	0.6170	0.6444	0.6304

ViT+DINO




Resultados Multiclase - EfficientNetB4




Resultados Multiclase - EfficientNetB4



	Precisión	Recall	F1 score
Melanoma	0.4823	0.5812	0.5271
Nevus	0.8833	0.6743	0.7648
Keratosis Seborreica	0.4214	0.7444	0.5382




Resultados Multiclase - Inception ResNet V2







Resultados Multiclase - Inception ResNet V2



	Precisión	Recall	F1 score
Melanoma	0.4385	0.7009	0.5395
Nevus	0.9351	0.5496	0.6923
Keratosis Seborreica	0.3956	0.8000	0.5294







Resultados Multiclase - Métricas globales

Modelos	Precisión	Macro-F1	Weighted-F1
ViT	0.7667	0.6885	0.7640
ViT+DINO	0.7667	0.6815	0.7606
EfficientNet B4	0.6667	0.6100	0.6845
Inception ResNet	0.6167	0.5871	0.6381

Métricas globales




6. Resultados. Resultados Binarios - Análisis ROC




Resultados Binarios - Análisis ROC



Modelos	ROC-AUC
ViT	0.826795
ViT+DINO	0.823910
EfficientNetB4	0.791085
Inception ResNet	0.797597




Resultados Binarios - Curva Precision-Recall



Resultados Binarios - Curva Precision-Recall



Modelos	Average Precision Score
ViT	0.603922
ViT+DINO	0.612988
EfficientNetB4	0.552100
Inception ResNet	0.528477



Resultados. Puntos Operativos

Escenario A - Cribado

- Prioridad: TPR muy alto
- $TPR \geq 0.95$ -> Mejor control: Inception-ResNet-v2
- $TPR \geq 0.85$ -> Menos FP y mejor PPV. Mejor equilibrio: ViT+DINO

Escenario B - Apoyo diagnóstico

- Prioridad: TNR alto. Se buscan pocos falsos positivos (evitar biopsias innecesarias)
- $TNR \geq 0.90$: Los ViT preservan mejor la sensibilidad que las CNN
- $TNR \geq 0.92$: se mantiene el patrón (ViT-based mejores)
- $TNR \geq 0.95+$: todos se vuelven conservadores → cae mucho la sensibilidad

El umbral determina el comportamiento clínico: subir TPR dispara FP; subir TNR aumenta FN. En regímenes moderados, los ViT ofrecen el trade-off más consistente.


Resultados. Análisis de Falsos Negativos - Transformers

- Error más común de Transformers: Melanomas predichos como Nevus
- Imágenes con artefactos (pelos, marcas de bolígrafo...)
- Lesiones de tamaño pequeño marcadas usualmente como Nevus.


T: melanoma | P: nevus
conf=0.92 pMel=0.07




T: melanoma | P: nevus
conf=0.88 pMel=0.04



T: melanoma | P: seborrheic_keratosis
conf=0.81 pMel=0.06



T: melanoma | P: nevus
conf=0.86 pMel=0.06




Errores cometidos por ViT

Errores cometidos por ViT+DINO


Análisis de Falsos Negativos - CNNs

- Error más común de CNNs: Melanomas predichos como Keratosis Seborreica
- Mucho más sensibles a artefactos
- Colores pálidos y formas difusas marcadas como Keratosis.


T: melanoma | P: seborrheic_keratosis
conf=0.83 pMel=0.09




T: melanoma | P: seborrheic_keratosis
conf=0.83 pMel=0.10



T: melanoma | P: seborrheic_keratosis
conf=0.76 pMel=0.15



T: melanoma | P: seborrheic_keratosis
conf=0.74 pMel=0.14



Errores cometidos por EfficientNetB4

Errores cometidos por InceptionResNetV2



7. Conclusiones

- **Liderazgo de ViTs:** Mejor rendimiento global (mayor precisión y ROC-AUC) y menos falsos positivos gracias a su comprensión del contexto.
- **Superioridad de CNN en Sensibilidad:** Inception-ResNet-v2 detectó más melanomas, siendo ideales para tareas de cribado (*screening*).
- **Selección según Objetivo Clínico:** Para *screening* se prefiere CNN (máxima sensibilidad); para reducir biopsias innecesarias, se prefiere ViT (mejor equilibrio).
- **IA como Apoyo, no Reemplazo**
- **Sesgo en Datos:** Falta de diversidad en tonos de piel
- **Futuro en Modelos Híbridos:** Métodos "Ensemble" que unan la sensibilidad de las CNNs con la robustez de los Transformers.